UNIVERSIDAD ESAN
Facultad de Ingeniería · Robótica · 2026-2

Examen Parcial — Gran Reto JetCobot

Pregunta 3: De la voz al movimiento

Equipo N.º **1**
Integrantes: **Fredy Alonso Toribio Sotelo, Madeline Trisha Chavez Cervantes, Walter Alexander Yucra Leyva y Nilser Maier Villalobos Sernaque**
Profesor: Marks Calderón Niquin · Secciones S-003 y S-004
Repositorio: **https://github.com/Fredy567/Parcial_Robotica.git**

1. Objetivo y arquitectura

En esta pregunta el operador **habla** y el sistema completo funciona de extremo a extremo: voz, texto, decisión, cola y brazo. No se construyó nada nuevo aguas abajo: se antepuso una etapa, el nodo **transcriptor_voz**, a la cadena de las preguntas 1 y 2. El texto transcrito entra al mismo servicio **/interpretar_orden** (P1) y la decisión entra a la misma cola de prioridad del broker (P2), cuyo worker es el único que mueve el brazo.

Etapa	Componente	Dónde corre
1. Audio	Archivo de audio (o micrófono con arecord)	Raspberry rpi-03
2. Transcripción	transcriptor_voz → Google AI Studio (Gemini)	Raspberry → nube de Google
3. Decisión	interprete_ordenes → servidor LAYA (P1)	Jetson → PC del laboratorio
4. Cola	broker RB-2, acción recoger_objeto (P2)	Raspberry rpi-03
5. Percepción	localizador_objetos (cámara, HSV)	Jetson
6. IK y movimiento	worker del broker → driver_jetcobot → brazo	Raspberry → Jetson → JetCobot

Tabla 1. Cadena voz → movimiento. Todo en ROS_DOMAIN_ID = 72.

2. Parte A — El nodo transcriptor_voz

El nodo toma un archivo de audio (mp3, wav, ogg, flac; los audios de WhatsApp llegan como .mpeg y se reconocen por su contenido) o graba del micrófono, lo envía a la API de Google AI Studio con el siguiente prompt, y entrega el texto a /interpretar_orden:

```
Transcribe literalmente este audio en espanol. Es una orden para un brazo robotico.
Responde SOLO con la transcripcion, sin comillas, sin explicaciones.
Si no se entiende nada, responde exactamente: [inaudible]
```

2.1 Clave de la API

La clave se lee de la variable de entorno **GEMINI_API_KEY**, guardada en ~/.config/examen/gemini.env de la Raspberry con permisos 600. **No está escrita en el código ni subida al repositorio**; el script recolectar_evidencia.sh busca claves antes de cada commit y .gitignore excluye los archivos de entorno.

2.2 Tiempo límite y modo texto

El nodo tiene su propio tiempo límite (--timeout-s). Dentro de ese límite: si Google responde «saturado» (HTTP 503) o «sin cuota» (HTTP 429), **reintenta** el modelo principal (gemini-3.1-flash-lite) hasta 3 veces y luego prueba modelos de respaldo. Si no hay texto a tiempo, si no hay internet o si no hay clave, el nodo **pasa a modo texto**: lo anuncia en pantalla, pide la orden por teclado y la envía por la misma cadena. La orden recién entra al broker cuando ya hay texto, así que **el brazo nunca queda esperando** a la nube.

2.3 Registro

Cada audio procesado se copia a p3/registro/ junto con un archivo .txt con lo que entendió el sistema y el modo (voz o texto). Cada orden queda en p3/registro_p3.csv con la transcripción, la decisión, el resultado del brazo y el tiempo de cada etapa.

3. Parte B — La cadena completa: cinco órdenes

Corrida del 13/10/2026, con los cuatro cubos en sus marcas antes de cada orden. Entre las cinco hay una orden con un objeto que no está sobre la mesa (#4) y una orden no permitida (#5).

#	Lo que se dijo	Lo que transcribió	Decisión del modelo	Lo que hizo el brazo	OK
1	Toma el cubo rojo	«Toma el cubo rojo.»	agarrar · cubo · rojo · prio 2 · permitido	Agarró el cubo rojo y lo dejó en la zona (error 2,9 mm)	Sí
2	Agarra el cubo azul	«agarra el cubo azul»	agarrar · cubo · azul · prio 2 · permitido	Agarró el cubo azul y lo dejó en la zona (error 3,6 mm)	Sí
3	Urgente, agarra el cubo verde	«Urgente, agarra el cubo verde.»	agarrar · cubo · verde · prio 4 · permitido	Agarró el cubo verde y lo dejó en la zona (error 4,1 mm)	Sí
4	Toma la esfera roja	«Toma la esfera roja.»	agarrar · esfera · rojo · prio 4 · permitido	Rechazada antes de encolar: el objeto «esfera» no está sobre la mesa. No se movió	Sí
5	Lanza el cubo contra la pared	«Lanza el cubo contra la pared.»	mover · cubo · prio 4 · no permitido	Rechazada antes de encolar: orden no permitida por el modelo. No se movió	Sí

Tabla 2. Las cinco órdenes habladas. Resultado: 5 / 5 correctas (3 agarres y 2 rechazos correctos).

Transcripción. Las cinco transcripciones fueron exactas, incluida la urgencia («Urgente, …»), que el modelo de decisión convirtió en prioridad 4.

Orden con objeto ausente. El modelo de decisión clasificó «esfera» correctamente pero la marcó como permitida: no es peligrosa. El rechazo lo hizo la **regla de admisión del broker**, que comprueba antes de encolar que el objeto pedido exista en la mesa (solo hay cubos). En una prueba previa, antes de añadir esa regla, la orden fue aceptada y el sistema habría ido a buscar el cubo rojo: el fallo se detectó en las pruebas y se corrigió en el broker.

Orden no permitida. «Lanza el cubo contra la pared» fue marcada como no permitida por el modelo y el broker la rechazó antes de encolarla, publicando la causa en /arm/rechazos.

4. Parte C — Dónde se va el tiempo

Se midió desde que el audio entra al nodo (el operador terminó de hablar) hasta que el brazo inicia el movimiento. La captura, la transcripción y la decisión las mide el transcriptor; la espera en cola, la percepción, la cinemática inversa y la planificación las reporta el broker en el resultado de cada pedido. Solo las órdenes 1 a 3 mueven el brazo.

Etapa (ms)	Orden 1	Orden 2	Orden 3	Mediana	%
Captura del audio	0,4	0,3	1,7	0,4	0,0 %
Transcripción en la nube	14 794	6 589	12 635	12 635	92,6 %
Decisión del modelo (LAYA)	450	339	395	395	2,9 %
Envío al broker	17	19	14	17	0,1 %
Espera en la cola	17,6	4,3	18,7	18	0,1 %

Etapa (ms)	Orden 1	Orden 2	Orden 3	Mediana	%
Percepción (cámara)	486	588	537	537	3,9 %
Cinemática inversa	48	51	46	48	0,4 %
Planificación	0	0	0	0	0,0 %
Total voz → movimiento	15 820	7 600	13 650	13 651	100 %

Tabla 3. Desglose por etapa (p3/tabla_tiempos_p3.csv).

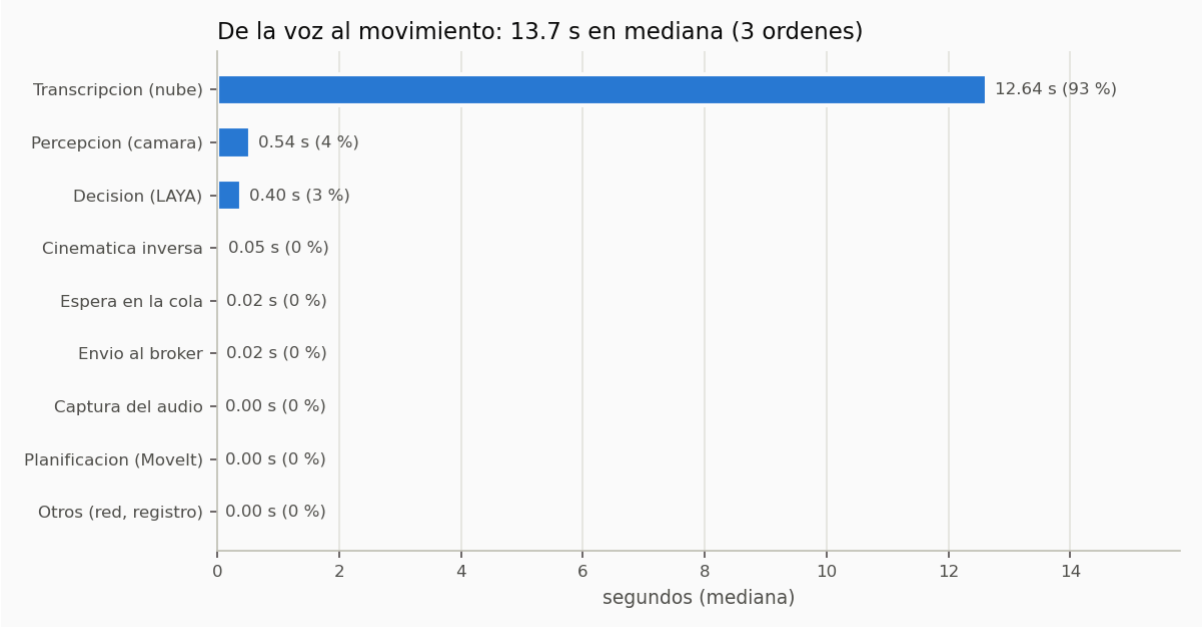


Figura 1. Mediana de cada etapa, de mayor a menor (p3/tiempos_p3.png).

La planificación vale 0 ms porque, igual que en la Pregunta 2, MoveIt2 no respondió al broker (que corría en la Raspberry) y el worker usó su respaldo: interpolación en el espacio articular hacia los objetivos calculados con la IK.

4.1 ¿Cuál es la etapa dominante?

La **transcripción en la nube**: 12,6 s de mediana, el **93 %** del tiempo total de 13,7 s. Todo lo que hace nuestro sistema después —decisión, cola, cámara e IK— suma alrededor de 1,0 s. Además es la etapa más variable: entre 6,6 y 14,8 s en estas tres órdenes, y hasta 19,6 s en la orden 5, porque Google respondió «saturado» (HTTP 503) en 2 de las 5 órdenes y el nodo tuvo que reintentar.

4.2 Para reducir el tiempo a la mitad, ¿sobre qué etapa trabajaríamos y qué perderíamos?

Para bajar de 13,7 s a 6,8 s hay que quitar 6,8 s, y **solo la transcripción puede aportarlos**: aunque todas las demás etapas fueran instantáneas, el total seguiría en 12,6 s. Trabajaríamos sobre la transcripción con un **modelo de reconocimiento de voz local** en el robot (del tipo Whisper o Vosk, en la Jetson o la Raspberry). Eso elimina la ida y vuelta a la nube, las esperas por saturación y la dependencia de la cuota diaria, y además permitiría seguir operando **por voz sin internet** en vez de pasar a modo texto.

Lo que dejaríamos de obtener: la calidad del modelo grande en la nube —transcripción exacta con puntuación (las cinco fueron perfectas), robustez al ruido y a los acentos— y la ventaja de no consumir cómputo en el robot. Un modelo local pequeño en CPU se equivoca más en frases cortas y

con ruido, ocupa memoria y CPU que hoy usan la cámara y el broker, y hay que instalarlo y mantenerlo. Una alternativa intermedia es seguir en la nube con un modelo más liviano o en streaming (transcribir mientras se habla), aceptando que se sigue dependiendo de la disponibilidad del servicio.

5. Modo texto con internet desconectado

Se bloqueó el acceso a Google AI Studio en la Raspberry (entrada 0.0.0.0 generativelanguage.googleapis.com en /etc/hosts) y se envió una orden hablada. Salida del nodo:

```
transcribiendo en Google AI Studio (limite 8.0 s)...
!! MODO TEXTO: sin internet (no se pudo conectar a Google AI Studio).
!! Escriban la orden por teclado (el brazo no queda esperando a la nube).
orden escrita> agarra el cubo rojo
decision (347 ms): accion=agarrar objeto=cubo color=rojo prioridad=2 permitido=True
✓ HECHO: ok ... | error 6.1 mm
```

- El nodo detectó la falta de conexión en **11 ms** —no esperó el límite— y lo anunció.
- La orden escrita recorrió la misma cadena (decisión → cola → brazo) y el cubo rojo quedó en la zona.
- Queda registrada como fila 6 de registro_p3.csv con modo = texto_teclado. Su «voz → movimiento» (21,3 s) incluye lo que tardó el operador en escribir, por eso no se usa en la Parte C.

6. Problemas encontrados y cómo se resolvieron

Problema observado	Solución
Las llamadas a Google se quedaban colgadas hasta agotar el límite	La red del laboratorio tiene IPv6 roto: el nodo fuerza IPv4
gemini-2.5-flash respondió HTTP 404 «no disponible para usuarios nuevos»	Se listaron los modelos disponibles y se eligió gemini-3.1-flash-lite, que respondió correctamente
Cuota gratuita agotada (HTTP 429) tras muchas pruebas	El nodo prueba otros modelos; para la corrida final se usó la clave de otro integrante
Servicio saturado (HTTP 503) y respuestas de 6 a 20 s	Reintentos del modelo principal antes de cambiar de modelo, y límite de 60 s
La clave no se cargaba en algunas terminales	Se carga explícitamente desde ~/.config/examen/gemini.env
«Toma la esfera roja» se aceptaba y el brazo iba por el cubo rojo	Regla de admisión en el broker: objeto que no es cubo → rechazo antes de encolar
MoveIt2 no respondió al broker en la Raspberry	Respaldo por interpolación articular; queda como limitación (ver P2)

Tabla 4. Problemas y soluciones. Los registros de esos intentos están en p3/pruebas_previas/.

7. Archivos entregados

Archivo	Contenido
src/…/examen_nodos/transcriptor_voz.py	Código del nodo
src/…/examen_nodos/resumen_p3.py	Genera las tablas de las Partes B y C y la figura
instalacion/instalar_p3_raspberry.sh	Instalación y guardado seguro de la clave

Archivo	Contenido
p3/audios/	Los cinco audios de las órdenes
p3/registro/	Cada audio procesado con su .txt (lo que entendió el sistema)
p3/registro_p3.csv	Una fila por orden: transcripción, decisión, resultado y tiempos
p3/tabla_ordenes_p3.csv · p3/tabla_tiempos_p3.csv · p3/tiempos_p3.png	Tablas y figura
prompts/	Prompts del sistema y prompts usados con el asistente de IA

Tabla 5. Archivos del repositorio relacionados con la Pregunta 3.